

Гуджаратиязычный корпус: источники данных и методология

Отчёт по к

1. Обзор

Гуджаратиязычный корпус — один из компонентов конвейера обработки текстовых корпусов, наряду с существующими источниками (arXiv, PubMed, Semantic Scholar, Springer, КиберЛенинка). Он состоит из четырёх независимых DAG обнаружения ссылок, разбитых по четырём смысловым категориям: художественная литература, новости/периодика, естественные науки и общественные науки.

Важное архитектурное решение: гуджаратский корпус НЕ использует отдельные таблицы базы данных. Все найденные ссылки пишутся в ту же таблицу PdfDocuments и обрабатываются тем же DAG pdf_downloading, что и все остальные источники — это позволило переиспользовать всю уже существующую инфраструктуру (пул прокси, повторные попытки, отслеживание успешности) без дублирования кода.

2. Механизм маркировки категорий

Поскольку в таблице PdfDocuments нет отдельного столбца категории, каждая найденная ссылка несёт свою категорию в виде фрагмента URL (часть после символа #), который никогда не отправляется по сети при самой загрузке файла — он используется только внутри конвейера для маршрутизации:

https://archive.org/download/{id}/{file}.pdf#gujarati_literature

DAG pdf_downloading распознаёт этот фрагмент, направляет файл в соответствующую подпапку на FTP-сервере и отбрасывает фрагмент перед фактическим HTTP-запросом (поскольку большинство серверов не ожидают получить символ # в самом запросе).

3. Источники по категориям

3.1. Художественная литература (gujarati_literature)

Источник:

- Критерий поиска: язык — гуджарати (guj), тип носителя — тексты (texts)
- Из выборки исключены темы «газета» и «журнал» (см. категорию «новости» ниже)
- Для каждого найденного элемента архива дополнительно запрашиваются его метаданные, чтобы найти реальное имя PDF-файла внутри архивного объекта

Запрос: те
AND M

Найдено (по состоянию на момент отчёта): 22 316 ссылок, из них скачано 572 файлов. Content включает как современные, так и исторические гуджаратские книги, оцифрованные в рамках проекта Digital Library of India и другими участниками Internet Archive.

3.2. Новости и периодика (gujarati_news)

Запрос: *mediatype:(texts) AND language:(guj)*
AND (subject:(newspaper) OR subject:(magazine))

Найдено: 1 004 ссылки, скачано 421 файл. Основную долю составляют выпуски долгоиздающегося культурно-литературного журнала «Kumar» (издаётся с 1920-х годов), а также отдельные отсканированные газетные выпуски. Целенаправленный скрапинг платных электронных версий газет (Gujarat Samachar, Sandesh, Divya Bhaskar) сознательно не используется — эти площадки являются платными сервисами с проприетарным доступом, тогда как Internet Archive предоставляет открытые сканы без ограничений доступа.

3.3. Естественные науки (*gujarati_science_natural*)

Категория

Источник 1 — Shodhganga (репозиторий INFLIBNET)

Shodhganga

язык диссертаций

Особенно

по главам

собирает

На момент отчёта данный источник не выдаёт результатов: подлинных диссертаций по естественным наукам на гуджарати в репозитории практически не оказалось — реальное явление нехватки контента, а не ошибка конвейера (высшее образование и научные публикации в Индии почти всегда ведутся на английском языке, даже в гуджаратиязычных регионах).

Источник 2 — Internet Archive (добавлен дополнительно)

Поскольку

категории

Запрос: *mediatype:(texts) AND language:(guj) AND (*
subject:(chemistry) OR subject:(physics) OR subject:(mathematics) OR
title:(chemistry) OR title:(physics) OR title:(mathematics))

Подтверждено вручную: найдено 8 подлинных материалов, включая учебник «RASAYAN» (химия для средней школы на гуджарати), гуджаратский перевод книги «Story of Physics» (в том числе версия в формате комикса), «Science Primers in Gujarati Physics» и исторические учебники математики на гуджарати («A course of mathematics in the Goojarati language»). Объём материала сознательно небольшой — это честное отражение реальной скудности научного контента на гуджарати, а не ограничение самого источника.

3.4. Общественные науки (*gujarati_science_social*)

Источник:

Критерий: язык — гуджарати, тема содержит «Social Science»,
«Economics» или «Sociology»

На момент отчёта результатов также не найдено — аналогичная ситуация с реальной нехваткой контента, как и в случае с естественными науками.

4. Структура хранения на FTP

Скачанные файлы сохраняются в отдельных подпапках, полностью изолированных от остальных источников (arXiv, Springer, КиберЛенинка):

```
/opt/pdfs/gujarati/  
literature/    <- художественная литература  
news/         <- новости и периодика  
science_natural/ <- естественные науки (2 источника)  
science_social/ <- общественные науки
```

Каждой категории соответствует ровно одна подпапка независимо от того, сколько источников её наполняет — это подтверждено прямой проверкой файловой системы: подпапки literature и news уже содержат реальные файлы, тогда как science_natural и science_social пока пусты, поскольку их наполнение только начинается либо ограничено нехваткой контента.

5. Текущая статистика (снимок на момент отчёта)

Категория	Найдено ссылок	Скачано	В очереди
Литература	22 316	572	21 727
Новости / периодика	1 004	421	577
Естественные науки	8 (+ Shodhganga)	0	8
Общественные науки	0	0	0

Категория «естественные науки» показывает 0 скачанных файлов на момент отчёта: новый источник (Internet Archive) был подключён непосредственно перед составлением отчёта, и обнаруженные 8 ссылок ещё не прошли полный цикл обработки (обнаружение -> постановка в очередь -> скачивание).

6. Справедливое распределение очереди между источниками

Все источники (включая четыре гуджаратских) конкурируют за общую очередь скачивания PdfDocuments. Изначально функция выборки следующей ссылки (GetPdfToDownload) не имела упорядочивания между источниками, из-за чего конвейер мог полностью исчерпать один источник (например, arXiv), прежде чем хотя бы раз обратиться к остальным. Это было исправлено введением циклического (round-robin) распределения: каждый вызов очереди переходит к следующему источнику по кругу, пропуская те, где сейчас нет доступных ссылок. Проверено вживую: последовательные вызовы теперь равномерно чередуют arXiv, КиберЛенинку, PubMed и гуджаратскую литературу вместо возврата только строк arXiv.

7. Известные ограничения

- Естественные и общественные науки на гуджарати — это ниша с объективно малым объёмом цифрового контента; дальнейшее расширение потребует поиска новых, пока не идентифицированных источников.
- Категория «новости» опирается исключительно на открытые архивные сканы (Internet Archive), а не на платные электронные версии современных гуджаратских газет — это

осознанное решение в пользу открытого доступа.

- Объём материала по категории «литература» на порядок превышает остальные категории — это отражает фактическое распределение оцифрованного гуджаратского контента в открытом доступе, а не смещение в дизайне конвейера.

Отчёт сформирован автоматически на основе фактической конфигурации DAG, прямых проверок API источников и текущего состояния базы данных TextCorpus / файловой системы FTP-сервера.